



Софийски университет „Св. Кл. Охридски“

Факултет по математика и информатика

Курсов Проект

на тема: „Генериране на препоръка за шегга чрез различни
препоръчващи системи“

Студент: Радослав Ботов, Изкуствен интелект

Учебна година: 2025/26

Курс: „Въведение в дълбокото самообучение“

Преподаватели: гл. ас. Кристина Арнаудова, ас. Симеон Христов

1. Въведение


Изследваме ефективността на различни архитектури за изграждане на препоръчващи системи в контекста на обработката на потребителски оценки за шегги. Основната цел е анализ и сравнителна оценка на класически и съвременни алгоритмични подходи, включващи филтриране, базирано на съдържанието, колаборативно филтриране както и архитектури с дълбоко обучение. Провеждаме кратък анализ на данните за да се запознаем с основните им характеристики. Разглеждаме как различните архитектури работят с данните и как се справят върху части от тях, които имат различни характеристики.

2. Данни – Jester Collaborative Filtering Dataset

Данните се състоят от 100 шегги и 73 421 потребителя разпределени на три файла. Два от тях се състоят от потребителите, които са оценили поне 36 шегги и третия съдържа потребителите, оценили между 15 и 35 шегги. За нашите цели, ще трансформираме оригиналните данни до по-подходящи формати:


a. Dense jokes (Шегги с повече оценки)

Обединяваме първите два файла, за да съберем потребителите оценили над 36 шегги на едно място. Така получаваме набор от 48 483 потребителя, които са оценили 72.59% от шегите. Валидна оценка, наричаме оценка със стойност между -10 и 10. Както се вижда от Фигура 1, шегите до номер 70, съдържат повечето оценки. Последните 30 шегги получават двойно по-малко оценки.



Фигура 1. Валидни оценки за всяка шега в данните с по-плътни оценки

На Фигура 2 може да видим как потребителите са оценявали шегите. Виждат се три по-големи скока на графиката около 40, 75 и 100 шегите. Това е броят шегите оценени от повечето потребители – около 4% от всички потребители са оценили 100 шегите, около 3% са оценили 75 шегите и т.н.



Фигура 2. Разпределение на валидните оценки между потребителите в данните с по-плътни оценки. Сумата под линията е едно.


На Фигура 3 може да видим какви стойности са дали потребителите за шегите. Най-големият скок е около нулата, т.е. много от оценките са неутрални. Все пак дясната част е по-висока от лявата – повечето оценки са положителни.



Фигура 3. Разпределение на стойностите на оценките в данните с по-плътни оценки


b. Sparse jokes (Шеги с по-малко оценки)

Третият файл, където потребителите са оценили между 15 и 35. Така получаваме набор от 24 938 потребителя, които са оценили 24.74% от шегите. Както се вижда от Фигура 4, шегите до номер 70, съдържат повечето оценки. Последните 30 шегите получават двойно по-малко оценки. Аналогични на Фигура 1, с разликата, че са много по-разредени.




Фигура 4. Валидни оценки за всяка шега в данните с по-разредени оценки

На Фигура 5 може да видим как потребителите са оценявали шегите. Вижда се един голям стълб между 15 и 35 оценки. Това е броят шегии оценени от повечето потребители – около 40% от всички потребители са оценили 100 шегии, около 30% са оценили 75 шегии и т.н.



Фигура 5. Разпределение на валидните оценки между потребителите в данните с по-разредени оценки.
Сумата под линията е едно.

На Фигура 6 може да видим какви стойности са дали потребителите за шегите. Най-големият скок е около нулата, т.е. много от оценките са неутрални. Все пак дясната част е по-висока от лявата – повечето оценки са положителни. Аналогично на Фигура 3, с разликата, че броят оценки е по-малко.



Фигура 6. Разпределение на стойностите на оценките в данните с по-разредени оценки

3. Препоръчващи системи базирани на съдържанието

Тези системи препоръчват елементи, които са сходни с тези, които потребителят е харесал в миналото, чрез анализ на характеристиките (съдържанието) на самите предмети, без да се използва сходство с други потребители. Използват се метрики за сходство (най-често косинусова близост) или техники от обработка на естествен език за изчисляване на близост между предмети (в този случай шегите). Подходите, които разглеждаме са:

- NormalPredictor: Използва се като базов модел. Той прогнозира оценките на случаен принцип, базирайки се на статистическото разпределение на оценките в тренировъчния набор, предполагайки че са нормално разпределени.
- TF-IDF (Term Frequency - Inverse Document Frequency): Използва се за претегляне на важността на думите в текстовото съдържание на вицовете. Сравнява „векторите“ на вицовете, за да намери сходство между тях. Построява се потребителски „профил“ от шегите вече оценени от даден потребител (тренировъчно множество) и се препоръчва най-сходната шегата от досега невиджани вицове (тренировъчно множество).
- BoW (Bag of Words): Подобно на TF-IDF, представя вицовете като „торби с думи“, игнорирайки граматиката и реда, но запазвайки честотата на срещане на думите. Препоръчва шегите аналогично на TF-IDF.

4. Колаборативни препоръчващи системи


Тези системи не анализират съдържанието на вицовете, а разчитат изцяло на историята от оценки на потребителите и сходството между тях. Те предполагат, че потребители с подобна история от шегите ще харесват подобни вицове и за в бъдеще.

- SVD (Singular Value Decomposition): Мощен метод за матрична факторизация, който намалява размерността на матрицата с оценки, разкривайки скрити латентни фактори, които обясняват предпочитанията на потребителите.
- KNNBasic (K-Nearest Neighbors): Алгоритъм, базиран на „съседите“. За да предскаже оценка, той намира k на брой потребители (или вицове), които са най-подобни на целевия обект, и изчислява средно претеглена оценка въз основа на техните предпочитания.

5. Препоръчващи системи базирани на дълбоко обучение

Използват се невронни мрежи, рекурентни невронни мрежи, автоенкодери и трансформери за моделиране на по-сложни, нелинейни зависимости между потребителите и елементите. В проекта разгледаме частно решение:

- RecommenderNet (Невронна мрежа): Мрежата се опитва да научи латентно представяне за всеки потребител и виц. Представянията се конкатенират и преминават през три дълбоки напълно свързани слоя. Изходния слой се свива до един изход, който преминава през активационната функция хиперболичен тангенс, за да свие изхода до $[-1, 1]$. Умножавайки по 10, получаваме оригиналния диапазон на оценките от $[-10, 10]$.



Фигура 7. Архитектура на Recommender Net

Хиперпараметър	Стойност
user_embedding_dim	# потребители в данните
joke_embedding_dim	100
embedding_dim	128
hidden_features	256
epochs	100
batch_size	1024

Таблица 1. Хиперпараметри на Recommender Net

6. Метрики и оценяване

Използваме метрики за точност (accuracy) и за класиране (ranking) на препоръките, които правят системите. Метриците за точност оценяват колко близо са прогнозните оценки до реалните такива, а метриците за класиране оценяват качеството на подредбата на препоръките.

- Root Mean Squared Error (RMSE): Изчислява корен квадратен от средната квадратична грешка. Метрика наказва по-строго големите отклонения между реални и прогнозираны стойности. Искане да минимизираме метриката.
- Mean Absolute Error (MAE): Изчислява средната абсолютна грешка. Тя дава директна представа за средното отклонение на прогнозата, без да акцентира върху големите грешки толкова силно, колкото RMSE. Искане да минимизираме метриката.
- Mean Reciprocal Rank (MRR): RR е метрика за оценяване къде се появява първият релевантен резултат в класирания списък. MRR осреднява стойностите от реципрочните рангове за всички заявки. Искане да максимизираме метриката.

7. Резултати

Прилагаме процедура за обучение и тестване на всички споменати подходи в точки 3, 4 и 5 като ги оценяваме с метриците описани в точка 6. Общо имаме три набора от данни за оценка: dense (потребителите оценили над 36 шага), sparse (потребителите оценили между 15 и 35 вица) и combined (всички потребители) и шест модела.

Model	Dataset	dense	RMSE sparse	comb	Percentage Improvement	dense	MAE sparse	comb	Percentage Improvement
Content-Based Recommender Systems									
NormalPredictor		7.2568	7.4441	7.2863	100.00%	5.8887	6.0686	5.9192	100.00%
TF-IDF		4.7943	5.1830	4.9288	147.50%	3.8091	4.0869	3.9316	151.14%
BOW		<u>4.7798</u>	<u>5.1509</u>	<u>4.9107</u>	148.15%	<u>3.8019</u>	<u>4.0691</u>	<u>3.9229</u>	151.57%
Collaborative-Based Recommender Systems									
SVD		4.3038	4.4217	4.4789	166.51%	3.3106	3.5148	3.4419	174.11%
KNNBasic		4.2783	4.4932	4.3123	168.05%	3.3546	3.5445	3.3834	173.85%
Deep Neural Recommender Systems									
RecommenderNet		5.4153	5.3875	5.4611	135.19%	4.0842	4.1300	4.1077	145.08%

Таблица 2. Резултати за RMSE и MAE върху различните набори от данни за предложените модели. Най-добрите модели са удебелени (bold). Вторите най-добри модели от друга категория са подчертани.

За основен модел използваме NormalPredictor, който приема че всяка шага има нормално разпределение и предсказва оценка за виц, случайно по тези разпределения.

От моделите базирани на съдържание TF-IDF и BoW моделите подобряват основата средно с около 50%. Макар че използват различни начини за представяне на текста на вицовете, разликите между метриките са незначителни. Те се оказват на второ място от тестваните подходи, като BoW е вторият най-добър подход след SDV и KNNBasic.

Колаборативните модели се оказват най-добри от тестваните подходи. Подобряват базовият подход с около 65~70%. SVD се справя по-добре на dense и sparse набори от данни, докато KNNBasic работи по-добре върху комбиниранияте данни.

Дълбоките невронни мрежи се оказват на трето място, близко до TF-IDF и BoW, различавайки се с ~5%. Те подобряват базовия модел с около 35-45%. Интересно наблюдение, което може да се направи за мрежата е че RMSE и MAE се различават с 10%. Моделите в другите подходи се различават с 2-5%. Това ни казва че мрежата се влияе силно от аномалии. Дори ни води до мисълта, че мрежата се пренагажда твърде много към тренировъчните данни. Тази мисъл се подкрепя и от загубата показана в Таблица 4.


Model	MRR			Percentage
Dataset	dense	sparse	comb	Improvement
Content-Based Recommender Systems				
NormalPredictor	0.6998	0.5780	0.6596	100.00%
TF-IDF	0.7148	0.6562	0.6848	106.11%
BOW	0.7116	0.6531	0.6846	105.78%
Collaborative-Based Recommender Systems				
SVD	0.8690	0.7397	0.8142	125.06%
KNNBasic	0.8682	0.7129	0.8192	123.89%
Deep Neural Recommender Systems				
RecommenderNet	<u>0.8128</u>	<u>0.7094</u>	<u>0.7774</u>	118.70%

Таблица 3. Резултати за MRR върху различните набори от данни за предложените модели. Най-добрите модели са удебелени (bold). Вторите най-добри модели от друга категория са подчертани.

От моделите базирани на съдържание TF-IDF и BoW моделите подобряват основата само с около 5%. На практика се справят идентично с основния модел. Те се оказват на трето и последно място от тестваните подходи при препоръки за нова шега.

Колаборативните модели отново се оказват най-добри от тестваните подходи. Подобряват базовия модел с около 25%. SVD се справя по-добре на dense и sparse набори от данни, докато KNNBasic работи по-добре върху комбиниранияте данни.

Дълбоките невронни мрежи се оказват на второ място, само с 5% разлика от най-добрите. Те подобряват базовия модел с 18% и са много по-добре от TF-IDF и BoW подходи. Макар че моделите базирани на съдържание бяха по-добри при MRSE и MAE, при генериране на нови препоръки RecommenderNet ги надминава.



Фигура 8. Загуба на RecommenderNet през 100 епохи върху тренировъчното множество на различните набори от данни

	dense	sparse	combined
Train set			
Epoch 0	29.0698	34.0488	30.1061
Epoch 100	1.4965	0.4472	1.5728
Test set			
Average Loss	29.3261	29.0257	29.8239

Таблица 4. Загуба на RecommenderNet върху тренировъчно и тестово множество на трите набора от данни

Както се вижда на Фигура 8, RecommenderNet намалява загубата си от ~30 до ~1 в тренировъчното множество за всеки набор от данни. Интересно е че sparse започва с по-голяма загуба, но завършва с по-малка в сравнение с dense и combined след 100 епохи, макар че има по-малко налични валидни оценки за обучение.

Проблемът е в тестовите множества. Загубата е много висока в сравнени с тренировъчните множества. Като вземем под предвид резултатите от Таблица 2, имаме основание да смятаме че модела се пренагажда към данните или има проблем в самата архитектура (пр. липса на dropout слой или твърде много dense слоеве, или проблем в хиперпараметрите).

Затова най-добрите резултати, които получаваме идват от SDV и KNNBasic моделите.

8. Бъдеща работа

Допълнителни експерименти и до настройване на RecommenderNet модела, за да открием и разрешим проблемите, с цел подобряване на колаборативните модели. Друг възможен подход за подобрене на резултатите и използването на друг вид архитектура за дълбоко самообучение като автоенкодер или трансформер. Интеграция на потребителски интерфейс чрез *Streamlit* за интерактивно уеб приложение за препоръки на шеги, а не само анализ на резултатите.

9. Заключение

Извършихме сравнителен анализ на различни подходи за препоръчващи системи за шеги. Проведените експерименти ни показват следните основни изводи:

- Методите SVD и KNNBasic се утвърдиха като най-ефективни, постигайки най-добри резултати по метриките RMSE, MAE, така и по MRR. Това показва, че сходството в поведението на потребителите е много по-силен индикатор за предпочитанията им, отколкото само текстовото съдържание на шегите.
- Макар TF-IDF и BoW подобряват резултатите спрямо базовия модел, те остават много по-слаби при препоръчване на нови вицове. Липсата на сложни семантични зависимости в тези модели ги прави недостатъчни за персонализирано препоръчване.
- Моделът RecommenderNet показва обещаващи резултати при класирането. Въпреки това, значителната разлика между загубата при тренировъчното и тестовото множество индикира сериозно пренагаждане (overfitting). Това подчертава необходимостта от по-нататъшна оптимизация на архитектурата.

В заключение, проектът демонстрира, че колаборативните методи остават достатъчно добри за препоръчваща система за сравнително по-малко време за имплементиране и трениране, докато дълбокото обучение притежава потенциал, който изисква по-прецизна архитектурна реализация, за да се разгърне напълно.

10. Ресурси

- [1] “Jester Collaborative Filtering Dataset.” *Berkeley.edu*, April 1999 - May 2003, goldberg.berkeley.edu/jester-data/.
- [2] Goldberg, Ken, et al. *Eigentaste: A Constant Time Collaborative Filtering Algorithm*. 2000.
- [3] Canny, John. *Collaborative Filtering with Privacy via Factor Analysis*. 2002.